

Masterarbeit-Tool

Erhebung, Aufbereitung und Auswertung offengelegter Firmenbuchdaten

AUTOR

Fabian Maier

SYSTEM

macOS · Python 3

BEDIENUNG

Webbrowser, lokal

DATENBESTAND

607 Gesellschaften · 2.723 Firmenjahre

01 Wozu dieses Werkzeug

Das Masterarbeit-Tool ist im Rahmen meiner Masterarbeit „*Bilanzanalyse österreichischer GmbHs auf Basis offengelegter Firmenbuchdaten*“ entstanden. Die Arbeit untersucht, welche strukturellen Muster die finanzielle Lage österreichischer GmbHs zeigt, wenn man sie ausschließlich aus öffentlich offengelegten Jahresabschlüssen rekonstruiert – und wie sich Branchen und Größenklassen darin unterscheiden. Ausgewertet werden die Geschäftsjahre 2019 bis 2025.

Für diese Erhebung gab es kein fertiges Werkzeug. Ich habe es deshalb selbst entwickelt, in reinem Python und ohne Fremdbibliotheken. Es ruft die Daten ab, ordnet jede Rohbezeichnung der Quelle einem Feld im Datenmodell zu, prüft sie auf Plausibilität und berechnet daraus die Kennzahlen. Zu jedem einzelnen Betrag wird festgehalten, woher er stammt.

ZWEI GRUNDSÄTZE, DIE DEN AUFBAU TRAGEN

Erhebung und Auswertung sind strikt getrennt. Die Rohdaten werden einmal gespeichert; jede Auswertung liest sie nur und berechnet die Kennzahlen bei jedem Aufruf neu. Keine berichtete Kennzahl stammt aus der Quelle.

Fehlend ist nicht gleich null. Nicht offengelegte Positionen bleiben als fehlend markiert und werden nirgends durch Nullen oder Schätzungen ersetzt.

Die Bedienung läuft vollständig über eine Oberfläche im Webbrowser. Die Anwendung startet lokal auf dem eigenen Rechner und ist von außen nicht erreichbar. Programmierkenntnisse sind für die Nutzung nicht erforderlich.

02 Voraussetzungen

- Ein Mac mit macOS
- Python 3 – auf aktuellen Systemen meist vorhanden. Fehlt es, genügt einmalig `xcode-select --install` im Terminal.
- Ein aktueller Webbrowser, etwa Safari, Chrome oder Firefox

KEIN ZUGANGSSCHLÜSSEL UND KEINE INTERNETVERBINDUNG NOTIG

Der Datenbestand liegt vollständig in der Datei `masterarbeit.db` im Projektordner. Sämtliche Auswertungen – Kennzahlen, statistische Tests, Größenklassen, Auffälligkeiten, Prognose – laufen ohne Internetverbindung. Eine Verbindung wird ausschließlich dann benötigt, wenn Sie selbst neue Daten erheben möchten.

03 Starten

Im Projektordner liegt der Ordner `Masterarbeit-Tool`. Darin befinden sich alle Dateien, die das Werkzeug braucht.

ZUERST VOLLSTÄNDIG ENTPACKEN

macOS zeigt ZIP-Dateien wie gewöhnliche Ordner an. Wird das Werkzeug direkt daraus gestartet, findet es seine Datenbank nicht. Der Projektordner muss deshalb erst vollständig entpackt und an einem festen Ort abgelegt werden, etwa unter `~/Downloads` oder auf dem Schreibtisch.

Weg A · Doppelklick

- 1 `Start.command` per Doppelklick öffnen.
- 2 macOS öffnet ein Terminalfenster und startet die Anwendung.
- 3 Im Browser `http://127.0.0.1:8731/` aufrufen. Dort erscheint die Oberfläche.

„VON EINEM NICHT VERIFIZIERTEN ENTWICKLER“

Diese Meldung erscheint beim ersten Start fast sicher. Es ist Gatekeeper, die Schutzfunktion von macOS: Aus dem Internet geladene Startdateien ohne kostenpflichtige Apple-Signatur werden blockiert. Geprüft wird dabei nur, ob eine Signatur vorliegt – nicht, was das Programm tut.

So geben Sie die Datei frei: Im Dialog auf **OK** klicken. Dann *Systemeinstellungen* → *Datenschutz & Sicherheit* öffnen und nach unten scrollen. Dort steht eine Zeile zu `Start.command` mit der Schaltfläche „Trotzdem öffnen“. Anklicken, bestätigen, danach die Datei erneut doppelklicken. Dasselbe gilt für `Diagnose.command`.

Weg B · Terminal — zuverlässiger, umgeht Gatekeeper

Gatekeeper greift nur beim Doppelklick im Finder. Ein direkt im Terminal gestartetes Python-Programm ist davon nicht betroffen. Terminal öffnen ($\mathbb{X}$ + Leertaste, „Terminal“) und eingeben:

```
cd ~/Downloads/Masterarbeit-Tool
python3 app.py
```

Liegt der Ordner an einer anderen Stelle: `cd` eintippen, ein Leerzeichen setzen und den Ordner aus dem Finder ins Terminalfenster ziehen – der Pfad wird automatisch eingefügt.

Nach dem Start erscheinen im Terminal ungefähr diese Zeilen:

```
Unternehmen    607
Firmenjahre    2723
Oberflaeche    http://127.0.0.1:8731/
Beenden       Strg + C
```

DAS TERMINALFENSTER MUSS OFFEN BLEIBEN

Solange das Werkzeug läuft, läuft es *in diesem Fenster*. Wird es geschlossen, ist die Anwendung sofort beendet und der Browser meldet „Server steht nicht zur Verfügung“. Genau das ist auch die Bedeutung dieser Meldung: Sie kommt vom Browser und heißt immer nur, dass die Anwendung nicht läuft.

04 Bedienung

Nach dem Start erscheint die Oberfläche im Browser. Alles Weitere geschieht dort – im Terminal sind keine Befehle einzugeben. Links liegt die Navigation mit zehn Ansichten.

Übersicht STARTSEITE	Umfang des Bestands, Verteilung über Branchen und Geschäftsjahre. Die großen Zahlen oben zeigen den gesamten Erhebungsbestand; die Branchentabelle darunter den Auswertungsbestand der fünf Zielbranchen.
Stichprobe HERLEITUNG	Wie aus der Grundgesamtheit die ausgewertete Stichprobe wurde. Zeigt je Branche, welcher Wortbestandteil im Firmenwortlaut wie oft gegriffen hat – und welche Gesellschaften kein Stichwort trägt.
Unternehmen EINZELFALL	Suche nach Firmenbuchnummer oder Name. Zeigt für eine Gesellschaft alle Geschäftsjahre mit Bilanzpositionen und Kennzahlen, darunter den Herkunftsnachweis zu jedem Einzelwert.
Kennzahlen BRANCHENVERGLEICH	Median je Branche mit 95-Prozent-Vertrauensbereich aus 1.500 Bootstrap-Ziehungen. Darunter der Kruskal-Wallis-Test auf Branchenunterschiede und die paarweisen Mann-Whitney-Vergleiche, korrigiert nach Benjamini-Hochberg.
Größenklassen NACH BILANZSUMME	Kennzahlen je Größenklasse, Median über alle Firmenjahre der Klasse. Die angewandten Schwellen der Bilanzsumme sind offengelegt.
Auffälligkeiten SCREENING	Die Regel über drei Dimensionen – auffällig ab zwei gleichzeitig kritischen. Zeigt den Anteil je Dimension und Branche sowie die auffälligen Firmenjahre, aufsteigend nach Eigenkapitalquote.
Prognose EXPLORATIV	Vorhersage der Auffälligkeit im Folgejahr, angelernt auf frühen Zieljahren und geprüft auf späteren. Zielgröße ist die selbst definierte Auffälligkeit – nicht die Insolvenz.
Datenabruf ERHEBUNG	Startet einen Erhebungslauf, um Daten zu aktualisieren oder neue Gesellschaften aufzunehmen. Für die Auswertung des mitgelieferten Bestands ist das nicht nötig – ausführlich beschrieben in Abschnitt 05.
Herkunftsnachweis NACHVOLLZIEHBARKEIT	Zuordnung von Rohbezeichnung der Quelle auf das Feld im Datenmodell, Belegung je Feld, und der Export aller Datenblätter als Trennzeichendatei.
Einstellungen BETRIEB	Zugang für den Live-Abruf, Inhalt der lokalen Datenbank, Hinweise zum Betrieb. Für die reine Auswertung ist hier nichts einzustellen.

DER ÜBLICHE WEG DURCH DAS WERKZEUG

Übersicht für den Umfang → *Kennzahlen* für den Branchenvergleich → *Unternehmen* für einen Einzelfall → *Herkunftsnachweis*, um zu sehen, woher ein einzelner Betrag stammt. Die Python-Dateien `app.py`, `kern.py` und `abruf.py` müssen dafür weder geöffnet noch verändert werden.

05 Neue Daten abrufen

Dieser Abschnitt wird nur gebraucht, wenn der Bestand erweitert oder aktualisiert werden soll. Für die Auswertung der mitgelieferten Daten ist er nicht nötig. Der Abruf läuft über die Ansicht *Datenabruf*.

Schritt 1 · Betriebsart wählen

Ganz oben stehen drei Schaltflächen. Die Auswahl entscheidet, was der Lauf tut:

Wiedergabe OHNE NETZ	Der bereits gespeicherte Bestand läuft erneut durch dieselbe Verarbeitungskette. Es wird nichts abgerufen und nichts verändert. Geeignet, um den Ablauf vorzuführen oder nachzuvollziehen – und die einzige Betriebsart, die ohne Internetverbindung funktioniert.
Bestand aktualisieren MIT NETZ	Ruft die Schnittstelle für die bereits erfassten Gesellschaften erneut ab und aktualisiert deren Werte. Die Zahl der Gesellschaften bleibt gleich; hinzukommen können neu offengelegte Geschäftsjahre.
Neue suchen MIT NETZ	Sucht über den Suchendpunkt bisher unbekannte Gesellschaften der gewählten Branche und ruft deren Jahresabschlüsse ab. Der Bestand wächst dadurch.

Schritt 2 · Umfang und Auswahl festlegen

- *Umfang* – wie viele Gesellschaften der Lauf bearbeitet. Die Schaltflächen setzen 10, 50, 200 oder *alle*. Ein leeres Feld bedeutet ebenfalls alle vorgemerkten Gesellschaften. Für einen ersten Versuch empfiehlt sich ein kleiner Umfang.
- *Branche* – schränkt den Lauf auf eine der fünf Branchen ein. *Alle Branchen* lässt die Auswahl offen.
- *Stichwörter* – nur für *Neue suchen* relevant. Bleibt das Feld leer, werden die für diese Branche hinterlegten Begriffe verwendet.

Schritt 3 · Lauf starten und beobachten

Ein Klick auf *Lauf starten* beginnt die Verarbeitung. Darunter laufen zwei Anzeigen mit:

- Die *Verarbeitungskette* zeigt, welcher der sechs Schritte gerade greift – Anfordern, Zerlegen, Zuordnen, Prüfen, Speichern, Berechnen – dazu Fortschritt, Firmenjahre, Einzelwerte und Fehler.
- Das *Verlaufsprotokoll* hält jeden Schritt fest, auch jeden Fehler mit Firmenbuchnummer und Meldung. Es ist die erste Stelle, an der man nachsieht, wenn etwas nicht wie erwartet läuft.

Ein laufender Abruf lässt sich jederzeit über *Anhalten* beenden. Bereits verarbeitete Gesellschaften bleiben gespeichert; der Lauf kann später fortgesetzt werden.

SCHONEND ABRUFEN

Zwischen den einzelnen Abrufen liegt eine Wartezeit, die unter *Einstellungen* eingestellt werden kann. Sie schont die Schnittstelle und beugt einer Sperre wegen zu häufiger Abfragen vor. Der voreingestellte Wert sollte nicht ohne Grund verringert werden. Ein Zugangsschlüssel ist nicht erforderlich – die Quelle ist frei zugänglich.

WENN OPENFIRMENBUCH.AT NICHT ERREICHBAR IST

Die Website ist gelegentlich nicht aufrufbar, weil sie zeitweise ausfällt. In diesem Fall bricht der Abruf ab oder das Verlaufsprotokoll meldet einen Fehler, etwa `Kennung 504`. Das liegt an der Quelle und nicht am Werkzeug.

Es hilft nur eines: *später noch einmal versuchen*. Ob die Schnittstelle wieder antwortet, lässt sich jederzeit unter *Einstellungen* mit der Schaltfläche *Verbindung prüfen* feststellen – ohne dass dabei ein Lauf gestartet oder etwas verändert wird. Erst wenn diese Prüfung erfolgreich ist, lohnt ein neuer Abruf.

Auf den mitgelieferten Datenbestand und sämtliche Auswertungen hat ein solcher Ausfall keine Auswirkung. Sie greifen ausschließlich auf die lokale Datenbank zu.

06 Beenden

Im Terminalfenster `Strg + C` drücken – das beendet die Anwendung sauber. Danach kann das Fenster geschlossen werden. Alternativ genügt es, das Terminalfenster zu schließen. Der Browser-Tab kann anschließend ebenfalls geschlossen werden; er hält keine Daten.

07 Wenn etwas nicht funktioniert

MELDUNG

URSACHE UND ABHILFE

„Server steht nicht zur Verfügung“

Kommt vom Browser, nicht vom Werkzeug: Auf Anschluss 8731 antwortet niemand, die Anwendung läuft also nicht. Über Weg B starten und die Terminalausgabe lesen.

„nicht verifizierter Entwickler“

Gatekeeper – siehe Abschnitt 03. Der Start über das Terminal umgeht die Meldung vollständig.

`command not found: python3`

Python fehlt. Einmalig `xcode-select --install` ausführen und die Installation bestätigen.

`No such file or directory`

Der Pfad stimmt nicht. Mit `ls ~/Downloads` prüfen, wo der Ordner tatsächlich liegt.

`Address already in use`

Die Anwendung läuft bereits in einem anderen Fenster. Entweder dieses verwenden oder es mit `Strg + C` beenden.

`Kennung 504` beim Datenabruf

Gateway-Timeout der Quelle: openfirmenbuch.at ist gerade nicht erreichbar. Später erneut versuchen und vorher unter *Einstellungen* die *Verbindung prüfen* – siehe Abschnitt 05. Auf den mitgelieferten Bestand und alle Auswertungen hat es keine Auswirkung.

Im Projektordner liegt zusätzlich `Diagnose.command`. Die Datei prüft die technische Umgebung und hilft bei Startproblemen. Auch hier gilt beim ersten Start die Gatekeeper-Freigabe aus Abschnitt 03.

08 Was im Ordner liegt

DATEI	FUNKTION
<code>Start.command</code>	Startet das Werkzeug per Doppelklick unter macOS.
<code>Diagnose.command</code>	Prüft die technische Umgebung bei Startproblemen.
<code>app.py</code>	Lokaler Webserver und Oberfläche. Wird beim Start ausgeführt.
<code>kern.py</code>	Kennzahlen, statistische Verfahren, Größenklassen, Prognose.
<code>abruf.py</code>	Erhebung: Abruf, Zerlegung, Zuordnung, Plausibilitätsprüfung.
<code>masterarbeit.db</code>	Die lokale Datenbank mit dem erhobenen Bestand.
<code>web/</code>	Bestandteile der Browseroberfläche.
<code>LIESMICH.md</code>	Technische Dokumentation zum Aufbau.

Schnellstart

Der kürzeste Weg zur laufenden Oberfläche.

1. Den Projektordner vollständig entpacken und an einem festen Ort ablegen.
2. Terminal öffnen, `cd` eintippen und den Ordner *Masterarbeit-Tool* hineinziehen. Eingabetaste.
3. `python3 app.py` eingeben. Eingabetaste.
4. Im Browser `http://127.0.0.1:8731/` öffnen.
5. Terminalfenster offen lassen. Zum Beenden dort `Strg + C`.